

Reconhecimento de Folhas de Plantas

July 1, 2026

Introduction

Objective

- Estudar, implementar e reproduzir o trabalho:


Stephen Gang Wu et al. A Leaf Recognition Algorithm for Plant Classification Using Probabilistic Neural Network. IEEE 7th International Symposium on Signal Processing and Information Technology, 2007. [link]

- A página do paper com o conjunto de imagens pode ser acessada neste link.

Paper

Dataset

O conjunto de dados é composto por imagens de 32 tipos de plantas.



Plants

label	Common Name	filename
1	pubescent bamboo	1001-1059
2	Chinese horse chestnut	1060-1122
3	Anhui Barberry	1552-1616
4	Chinese redbud	1123-1194
5	true indigo	1195-1267
6	Japanese maple	1268-1323
7	Nanmu	1324-1385
8	castor aralia	1386-1437
9	Chinese cinnamon	1497-1551
10	goldenrain tree	1438-1496
11	Big-fruited Holly	2001-2050
12	Japanese cheesewood	2051-2113
14	wintersweet	2114-2165
15	camphortree	2166-2230
16	Japan Arrowwood	2231-2290
17	sweet osmanthus	2291-2346

label	Common Name	filename
18	deodar	2347-2423
19	ginkgo, maidenhair tree	2424-2485
20	Crape myrtle, Crepe myrtle	2486-2546
21	oleander	2547-2612
22	yew plum pine	2616-2675
23	Japanese Flowering Cherry	3001-3055
24	Glossy Privet	3056-3110
25	Chinese Toon	3111-3175
26	peach	3176-3229
27	Ford Woodlotus	3230-3281
28	trident maple	3282-3334
29	Beale's barberry	3335-3389
30	southern magnolia	3390-3446
31	Canadian poplar	3447-3510
32	Chinese tulip tree	3511-3563
33	tangerine	3566-3621

Introdução

- **Contexto:** A preservação de plantas é crucial, mas muitas espécies estão em risco de extinção.
- **Desafio:** Identificar plantas manualmente exige especialistas; sistemas automatizados são necessários.
- **Abordagem:** Uso de imagens de folhas como principal método de classificação devido ao baixo custo e conveniência.
- **Objetivo do Artigo:** Propor um algoritmo que extraia características morfológicas automaticamente e as classifica usando Redes Neurais Probabilísticas (PNN).

Fluxo do Algoritmo Proposto

Processo de 6 Etapas:

1. Captura da imagem digital da folha.
2. Pré-processamento da imagem.
3. Extração de características (Features).
4. Análise de Componentes Principais (PCA).
5. Treinamento da Rede Neural (PNN).
6. Teste e Comparação de Resultados.

Extração de Características da Folha

Características da Folha

- No paper, os autores consideram algumas características (medidas) obtidas a partir das imagens das folhas.
- No paper, os autores consideram dois tipos de características: (1) geométricas; e (2) morfológicas digitais.

Extração de Características da Folha

Características Geométricas:

1. Diâmetro (D)
2. Área da Folha (A)
3. Perímetro da Folha (P)
4. Comprimento Fisiológico (L_p)
5. Largura Fisiológica (W_p)

Características Morfológicas Digitais:

1. Fator de Suavização (S)
2. Proporção de aspecto (L_p/W_p).
3. Fator de forma ($4\pi A/P^2$).
4. Retangularidade ($L_p W_p/A$).
5. Fator de estreitamento (D/L_p).
6. Razão Perímetro-Diâmetro (P/D)
7. Razão
Perímetro-Medidas-Fisiológicas
($P/(L_p + W_p)$)
8. 5 Características das veias
(V_1, V_2, V_3, V_4, V_5)


Características Geométricas

- Você deverá implementar funções para obter as características geométricas
- As 3 primeiras características geométricas deverão ser implementadas como descritas no paper.
- As 2 últimas características são obtidas manualmente no paper (veja próximo slide).

Obter L_p e W_p de cada Folha


- No artigo, o valor de L_p é obtido marcando os extremos do nervo central da folha manualmente.
- O valor de W_p é obtido pela maior distância entre os pontos da borda da folha perpendicular ao eixo do nervo central.

Comprimento e Largura Fisiológicas (L_p e W_p)




L_p e W_p Calculados Automaticamente

No EP2, os eixos do central **deverão** detectados automaticamente.




L_p e W_p Calculadas Automaticamente

Vamos usar **Análise de Componentes Principais** (PCA) - como mostrada em aula - para encontrar os eixos do nervo central e posteriormente os valores de L_p e W_p .



L_p e W_p Calculadas Automaticamente (PCA)

Usar PCA como mostrada em aula



Análise de Componentes Principais (PCA) da Borda

- **Entrada:** conjunto de pixels $\{(x_i, y_i) : i = 1, 2, \dots, n\}$ da borda em forma matricial X em que as linhas são os pontos e as colunas contêm as características, ou seja, $X_{n \times 2}$.
- **Saída:** autovalores e autovetores.

Consideramos um conjunto de dados com **n** observações e **2** coordenadas.

$$X_{n \times 2} = \begin{bmatrix} x_1 & y_1 \\ \vdots & \vdots \\ x_n & y_n \end{bmatrix}$$

- As **linhas** representam os pixels (amostras) da borda.
- As **colunas** representam as coordenadas dos pixels.

Matriz de Covariância

Os primeiros passos do PCA é obter a **matriz de covariância**:

1. Considere agora que x_i é a i -ésima linha da matriz X .
2. Encontrar o ponto médio $\bar{x}$ dos pontos

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

3. Deslocar os pontos para o centróide

$$\tilde{x}_i = x_i - \bar{x}$$

4. Calcular a matriz de covariância Σ

$$\Sigma = \frac{1}{n-1} \tilde{X}^t \tilde{X}$$

Autovalores e Autovetores da Matriz de Covariância

Buscamos os vetores v que não mudam de direção (apenas a escala λ) sob a transformação linear da matriz de covariância.

$$\Sigma v = \lambda v$$

Autovetores (v)

Definem as **direções** dos novos eixos (Componentes Principais).

Autovalores (λ)

Representam a magnitude da **variância** explicada em cada direção.

Base Ortonormal


Os eixos formam um ângulo de 90° e são normalizados ($\|v\| = 1$) para indicar apenas a direção.

Cálculo dos Autovalores e Autovetores

- Usar uma função do `numpy` para obter os autovalores λ_1 e λ_2 (com $\lambda_1 \geq \lambda_2$) e os correspondentes autovetores v_1 e v_2 .
- Para garantir a norma 1, fazer

$$u_1 = \frac{v_1}{||v_1||} \quad u_2 = \frac{v_2}{||v_2||}$$

Cálculo dos Autovalores e Autovetores




Visão Geométrica

O PCA rotaciona o sistema de coordenadas original para se alinhar com a forma natural dos dados.


A **Elipse de Covariância** visualiza essa estrutura: os eixos da elipse são os autovetores, e seus comprimentos são proporcionais aos autovalores.

PC1: Eixo maior da elipse.

PC2: Eixo menor (ortogonal ao PC1).



Obtenção dos pontos extremos p_1 e p_2



Cálculo dos pontos extremos p_1 e p_2

Uma forma de obter os pontos extremos p_1 e p_2 é:

1. Projetar os pontos da borda da folha centralizada $\tilde{X}$ em u_1 .

$$\pi = \tilde{X} \cdot u_1$$

2. O ponto x_i de $\tilde{X}$ que tenha a **menor** projeção é o ponto p_1 , ou seja,

$$p_1 = \arg \min_{\tilde{x}_i \in \tilde{X}} \{ \tilde{x}_i \cdot u_1 \}$$

3. O ponto x_i de $\tilde{X}$ que tenha a **maior** projeção é o ponto p_2 , ou seja,

$$p_2 = \arg \max_{\tilde{x}_i \in \tilde{X}} \{ \tilde{x}_i \cdot u_1 \}$$

1. L_p é a distância $\|p_1 - p_2\|$

Cálculo dos pontos extremos q_1 e q_2

Uma forma de obter os pontos extremos q_1 e q_2 é:

1. Projetar os pontos da borda da folha centralizada $\tilde{X}$ em u_1 .

$$\pi = \tilde{X} \cdot u_2$$

2. O ponto x_i de $\tilde{X}$ que tenha a **menor** projeção é o ponto q_1 , ou seja,

$$q_1 = \arg \min_{\tilde{x}_i \in \tilde{X}} \{ \tilde{x}_i \cdot u_2 \}$$

3. O ponto x_i de $\tilde{X}$ que tenha a **maior** projeção é o ponto q_2 , ou seja,

$$q_2 = \arg \max_{\tilde{x}_i \in \tilde{X}} \{ \tilde{x}_i \cdot u_2 \}$$

1. W_p é a distância $\|q_1 - q_2\|$

Características Morfológicas Digitais


- Uma vez obtidas as 5 características geométricas, você deve implementar as funções para obter as características morfológicas digitais (veja Slide 11).
- Com exceção da primeira (S) característica morfológica digital, implemente funções para as características como descritas no paper.
- Para a primeira característica (S), em vez de usar o filtro da média (como indicado no paper) use erosão aplicada na imagem binária da folha com elementos estruturantes 5×5 e 3×3 . E obtenha a razão entre as áreas dos resultados.
- Para as 5 últimas características, veja os discos no slide seguinte.

Discos


Elementos estruturantes em formato de disco com raio variando de 1 a 4.




Raio 1



Raio 2



Raio 3



Raio 4

Observação: O *foreground* é escuro.

Matriz Folhas x Características

- No final, você terá para cada imagem de folha, valores correspondentes às 12 características morfológicas digitais.
- Como temos 1907 imagens de folhas no conjunto de dados, podemos montar uma matriz de dados $F_{n \times d}$, onde $n = 1907$ é o número de folhas e $d = 12$ é o número de características.

Redução de Dimensionalidade

PCA para as características morfológicas digitais

- No paper, as 12 características morfológicas digitais são reduzidas para 5 características (componentes principais) obtidas por PCA.
- Ou seja, a matriz $F_{1907 \times 12}$ deve ser transformada em uma matriz $G_{1907 \times 5}$.

Parte 2 do EP2

Tarefas para a parte 2 do EP2

- Você deverá implementar a função para calcular os autovalores e autovetores de um conjunto de dados $X_{n \times d}$.
- Você deverá implementar a função para obter p_1 , p_2 , q_1 e q_2 a partir da borda da folha.
- Você deverá implementar as funções para obter as características geométricas da folha.
- Você deverá implementar as funções para obter as características morfológicas digitais da folha (função para obter a matriz $F_{n \times 12}$).
- Você deverá implementar a função para obter as características dos 5 componentes principais (função para obter a matriz $G_{n \times 5}$).

As mesmas condições para a Parte 2

- Implemente suas funções em um jupyter notebook, incluindo texto e códigos, na forma de um relatório, de maneira que na leitura entenda o que foi feito.
- Para o seu código, as únicas bibliotecas permitidas são: (1) `numpy`; e (2) `matplotlib`. Outras bibliotecas, como `cv2`, `skimage`, `scipy`, não são permitidas e seu uso levará a descontos grandes na avaliação.
- Na avaliação será considerado a clareza do "relatório" e do código. Portanto, capriche no seu trabalho.
- Entregue esse jupyter notebook no edisciplinas até a data 16/07/2026.